

利用深度学习的运动声源线谱增强方法*

严梓钰^{1,2} 沈同圣^{1,2} 罗再磊^{2†} 李雄辉^{2,3} 唐建中^{1,4} 杨植凯²

(1 浙江大学 海洋学院 舟山 316021)

(2 国防科技创新研究院前沿交叉技术研究中心 北京 100071)

(3 哈尔滨工程大学 水声工程学院 哈尔滨 150001)

(4 浙江大学 机械工程学院 杭州 310058)

2023 年 8 月 10 日收到

2023 年 10 月 9 日定稿

摘要 针对运动声源线谱存在的低信噪比、多普勒频移等情况,提出了使用基于监督学习的深度学习实现线谱增强。训练数据为本地生成的干净和含噪线谱数据对。分别采用直接参数映射和比值掩码方法进行训练并建立线谱增强模型,最后使用两种模型处理了仿真数据与 SWellEx-96 实验数据,并将处理结果与传统的增强方法进行对比。对于仿真数据,两种模型均可用于线谱增强,且均具备加强多线谱和多普勒频移线谱的能力。当信噪比为 -35 dB,两种模型可分别实现约 11.74 dB 信噪比增益和 7.52 dB 降噪。对于 SWellEx-96 实验数据,Masking 模型对多普勒频移性质的线谱具有良好的不失真性质,证明了所提深度学习模型应用于运动声源线谱增强的可行性。

关键词 线谱增强,深度学习,运动声源,多普勒频移

PACS: 43.60, 43.30

DOI: 10.12395/0371-0025.2023164

CSTR: 32049.14.11-2065.2023164

Moving sound source line spectrum enhancement method using deep learning

YAN Ziyu^{1,2} SHEN Tongsheng^{1,2} LUO Zaili^{2†} LI Xionghui^{2,3} TANG Jianzhong^{1,4} YANG Zhikai²

(1 School of Oceanography, Zhejiang University Zhoushan 316021)

(2 National Innovation Institute of Defense Technology, Advanced Interdisciplinary Technology Research Center Beijing 100071)

(3 School of Underwater Acoustic Engineering, Harbin Engineering University Harbin 150001)

(4 School of Mechanical Engineering, Zhejiang University Hangzhou 310058)

Received Aug. 10, 2023

Revised Oct. 9, 2023

Abstract Considering the low signal-to-noise ratio (SNR) and Doppler frequency shift of the line spectrum of a moving sound source, this paper proposes a deep learning method based on supervised learning to achieve line spectrum enhancement. The training datasets are locally generated clean and noisy line spectra, which are trained by mapping and masking methods, respectively. Finally, the simulation data and the SWellEx-96 experimental data are compared and verified with the traditional enhancement method. For the simulation data, both models can be used for line spectrum enhancement, and both models could enhance multi-line spectrum and line spectrum with Doppler frequency shift. When the input SNR is -35 dB, the two models can achieve about 11.74 dB SNR gain and 7.52 dB noise reduction, respectively. For the SWellEx-96 dataset, the masking model has undistorted property for the line spectra with Doppler shift, which proves the feasibility of applying the proposed deep learning model to enhance the line spectra of moving sound sources.

Keywords Line enhancer, Deep learning, Moving sound source, Doppler shift

* 国家自然科学基金项目 (41906169) 资助

† 通讯作者: 罗再磊, zaili Luo@163.com

引言

无源声呐探测往往关注接收信号中的低频线谱分量^[1,2],水下目标辐射噪声中的线谱成分是由船载机械装置振动、螺旋桨旋转等因素形成的,具有较强的谱峰特性及稳定性,包含有大量的被测目标信息^[3]。因此线谱增强对水下目标的无源检测具有重要意义^[4]。然而在水声目标无源识别实际场景中,目标发声机理复杂、海洋信道时空变异、背景和平台噪声、被测目标与声呐之间存在相对运动等因素导致水声目标辐射噪声信噪比较低,线谱会出现多普勒频移等现象。

传统增强方法主要采用自适应谱线增强器(ALE)、维纳滤波器(WF)等增强信号^[5-7],即主要利用线谱的相干特性,匹配未知线谱信号,抑制加性宽带噪声以增强线谱信噪比。但是当信噪比低于一定阈值时增强效果会迅速恶化,文献[7]仿真结果表明当信噪比低于一定条件时 ALE 很难获得增益且无法实现对非线性噪声进行降噪。为了克服上述限制,本文尝试使用深度学习技术实现线谱增强。

目前,深度学习方法广泛应用于声学领域^[8,9],在空气声学领域,由于存在大量生物学试验样本数据,该技术发展较为成熟,2015 年 Han 等^[10]将深度神经网络(DNN)与 WF 相结合,从带噪语音中同时估计出干净语音和噪声的幅度谱,然后利用估计的干净语音幅度谱和原带噪语音的相位重新合成增强语音。2018 年 Baby 等^[11]将具有时序建模能力的长短时记忆神经网络(LSTM)加入模型中,同样在幅度谱上使用比值掩码进行语音增强。2020 年 Takeuchi 等^[12]利用 T-F 谱完全重构的性质,使用 DNN 实现了一种基于 T-F 谱的端到端语音增强。但是目前使用深度学习算法构建无源声呐线谱增强的研究较少。2020 年,鞠东豪等^[13]将深度学习技术应用于水下声信号线谱增强,并使用非监督学习的方式实现了线谱增强目标,对于输入信噪比为-30 dB 的仿真数据,该方法仍可实现 20 dB 的信噪比增益,但未对含有多普勒频移性质的目标线谱进一步研究。2021 年,Chen 等利用卷积神经网络(CNN)进行线谱增强以恢复 LOFAR 频谱中的断点。而相对于非监督学习,监督学习所需训练数据量更小,环境适用性更强,且具有良好的不失真性等。

本文将具有监督的深度学习方法应用于水声信号线谱增强。为了应对现实水下的复杂环境,训练数据集是由本地生成的干净和含噪线谱数据对,以进

一步探究模型应用于水声信号线谱的增强性能。模型采用频谱直接映射(Mapping)和比值掩码(Masking)两种方法进行训练。最后,使用两种模型处理了仿真数据与 SWellEx-96 实验数据,并将处理结果与传统方法增强方法进行对比。

1 深度学习模型

1.1 基于 Mapping 模型的水声信号线谱增强

采用 DNN 作为从噪声到干净频谱特征的映射函数^[14], Mapping 线谱增强流程如图 1 所示。

在训练阶段,利用噪声和干净线谱数据的对数功率谱特征训练基于 DNN 的回归模型。在增强阶段,通过训练好的 DNN 模型对含噪频谱特征进行处理,预测干净的频谱特征 $\hat{X}_{LPS}(d)$,在得到干净频谱的预测对数功率谱特征后,重建的谱为

$$\hat{X}_f(d) = \exp\{\hat{X}_{LPS}(d)/2\} \exp[j\angle Y_f(d)], \quad (1)$$

式中, d 代表第 d 维的数据, $\angle Y_f$ 为含噪线谱的相位。为了增强后线谱相位的有效性,增强线谱为原数据样本的相位^[10]。波形重构的方式采用短时傅里叶逆变换(ISTFT)和交叠相加的方法^[15]以实现合成频谱并输出线谱增强结果。

在 DNN 训练方面,采用具有多层非线性结构的前馈神经网络,该网络的目标是构成一个高度非线性的回归函数,将有噪声的线谱特征映射到干净的线谱特征。DNN 总体训练框架如图 2 所示。

模型输入为连续的 n 帧对数功率谱特征,其中中间帧为第 i 帧,以时域维度向两侧分别拓展 τ 帧,即 $n = 2\tau + 1$,每帧长度记为 T ,每次步进 1 帧。训练特征数据均需进行标准正则化处理,以加快模型收敛速度,标准正则化公式为

$$X_i^{\text{in}} = \frac{2X_i - (X_{\max} + X_{\min})}{X_{\max} - X_{\min}}, \quad (2)$$

式中 X 为样本数据, i 为样本索引, $X_{\max}$ 和 $X_{\min}$ 分别




图1 Mapping 线谱增强流程图




图2 DNN 训练架构

为样本数据最大值和最小值, X^{in} 为输入样本。

在学习过程中, 使用 DNN 学习映射函数, 在给定足够的训练样本的情况下, 该算法能够自动学习含噪线谱和干净线谱之间的复杂关系。隐藏单元的类型为 Sigmoid 型, 层数为 3; 输出单元类型为线性, 输出则每次预测出中间帧第 i 帧, 最边缘两帧的输出则直接采用原频谱最边缘两帧。

然后以基于最小均方根误差 (MMSE) 的目标函数在估计线谱的归一化对数功率谱特征和参考干净线谱之间反向传播算法训练深度神经网络。采用小批量随机梯度下降算法改进误差函数, 误差函数为

$$Er = \frac{1}{N} \sum_{n=1}^N \left\| \widehat{X}_n(Y_{n-\tau}^{n+\tau}, W, b) - X_n \right\|_2^2, \quad (3)$$

式中, Er 为均方误差, $\widehat{X}_n(Y_{n-\tau}^{n+\tau}, W, b)$ 和 X_n 分别表示索引为 n 的样本估计值和参考值归一化对数功率谱特征; W 为模型学习的权重, b 为偏置参数。指定学习率, λ 更新第 l 层中 W^l 和 b^l 的估计值, 迭代计算如下:

$$\Delta(W_{n+1}^l, b_{n+1}^l) = -\lambda \frac{\partial Er}{\partial (W_n^l, b_n^l)} - \kappa \lambda (W_n^l, b_n^l) + \omega \Delta(W_n^l, b_n^l), \quad 1 \leq l \leq L+1, \quad (4)$$

式中, L 为隐藏层总数, $L+1$ 为输出层, κ 为权重衰减系数, w 为动量。本文 Mapping 模型的参数为: 单帧长度 20 ms, 单边拓展帧数 3 帧, 模型学习率 0.001, 批量大小 32, 丢弃率 0.1。

1.2 基于 Masking 模型的水声信号线谱增强

利用深度学习模型将水声信号输入的频谱特征映射成相应的掩模, 再将掩模和频谱特征相乘, 得到增强后的结果, 最后经特征逆转换后得到增强线谱^[16]。Masking 线谱增强流程如图 3 所示。

与 Mapping 模型不同, 在训练阶段, Masking 模型主要输入的频谱特征为连续帧的掩码值与频谱特征相乘的结果。本文使用的掩码公式为

$$\text{Masking} = \left(\frac{Px(f, t)}{Px(f, t) + Pn(f, t)} \right)^\beta, \quad 0 \leq \beta \leq 1, \quad (5)$$

式中, P 为信号功率, β 为线谱功率相对于总功率的权重。Masking 模型使用的 DNN 模型与损失反馈函数与 Mapping 模型相同。Masking 模型对线谱中低频线谱分量与宽带噪声分量的功率比值较为敏感,




图3 Masking 线谱增强流程图

更有利于保留原始信号信息,理论上具备更好的不失真性质^[17]。本文 Masking 模型的参数:单帧长度 20 ms,单边拓展帧数 3 帧,模型学习率 0.01,批量大小 32,丢弃率 0.1, β 为 0.5。

2 数据集

2.1 基于时频谱的特征提取

声呐接收信号噪声通常为加性噪声^[18],以由宽带噪声分量和线谱分量构成的经典声呐接收信号模型为例:

$$x(t) = \sum_{i=1}^M A_i \sin(2\pi f_i k + \varphi_i) + n(t), \quad (6)$$

式中, $A_i \sin(2\pi f_i k + \varphi_i)$ 为低频线谱分量, M 为线谱数量, t 表示在时域上的采样时间, $n(t)$ 为噪声分量。

水下无源声呐检测中,希望在线谱增强的同时力求真实环境中线谱不失真^[19]。为用深度学习方法获得更高增益的信噪比和不失真模型,一个关键环节是选择作为训练特征的特征。水声信号中窄带谱的能量和频率较宽带频谱更集中和稳定^[20],因此对接收的水声信号时域数据做时频变换以获取线谱特征,时频谱主要通过短时傅里叶变换 (STFT) 得到:

$$X(f, t) = S(f, t) + N(f, t). \quad (7)$$

对数功率谱与相位分别为

$$X_{LPS}(f, t) = 10 \log_{10}(|X(f, t)|^2), \quad (8)$$

$$\angle X(f, t) = \arctan(X(f, t)), \quad (9)$$

式中, $|\cdot|$ 为取模运算, X_{LPS} 为信号的幅度谱。评价指标采用信噪比增益 G 与线谱不失真性,信噪比增益/降噪定义为

$$G(\text{dB}) \triangleq 10 \log_{10} \frac{\text{Mean}(C_{LS}(i))}{\text{Mean}(C_N(j))}, \quad (10)$$

式中, C_{LS} 和 C_N 分别为线谱的信号功率和背景噪声的信号能量, i 和 j 分别为线谱的采样点数和背景噪声对应的采样点数, $\text{Mean}(\cdot)$ 为计算平均。

针对传统和深度学习方法在线谱增强过程中存在线谱失真的现象,本文方法在增强线谱的基础上不凭空构建出新线谱或改变线谱数量,在密集分布的线谱之间不进行自动能量填充,对于粗细不均和弯曲频移的线谱不改变线谱本身形状特性。

2.2 训练数据

目前实验数据标签标定困难,尝试使用本地生成的仿真数据改善有监督学习对于水声信号线谱增

强缺少标签的问题。训练数据包含一组干净线谱、含噪线谱数据对,且未预设含噪线谱和干净线谱之间的关系,干净线谱数据将作为模型训练的标签。

训练数据线谱随机分布在 50~1000 Hz,分辨率为 0.01 Hz,信噪比为 -35 dB,添加噪声类型为高斯白噪声。仿真数据试验中,使用式 (6) 的信号模型构建线谱,除生成单线谱之外,还生成双线谱和三线谱作为训练集子集以测试深度学习模型的多线谱增强的能力。基于深度学习方法的线谱增强流程见图 4。

实验中随机选取每个子数据集中 20% 的样本数据作为训练集来训练模型,其余 80% 作为测试集对模型进行测试。此外,为避免过拟合,在训练集中随机选取 50% 的有效数据样本进行模型参数优化,其余 50% 用于验证参数优化的结果,即参与模型只占数据集的 10%。本文用于训练数据的采样频率为 2000 Hz,单线谱、双线谱和三线谱各 1000 对。

然后,利用 Mapping 和 Masking 两种深度学习方法建立水声信号线谱增强模型。对于模型方法之间的性能比较,两种方法都使用相同的训练数据和测试数据集,详见第 3 节。

最后,将信噪比增益 G 及频谱的不失真性作为本文模型的评价指标。




图 4 基于深度学习的水声线谱增强流程图

3 实验结果

3.1 静止目标仿真数据实验结果

仿真测试单线谱、双线谱和三线谱数据集数量均为 8000 组,其采样频率为 2000 Hz,信噪比为 -35 dB。随机选择相同的单线谱和三线谱对应不同模型的增强结果为例进行展示,其中单线谱的频点为 251.11 Hz,三线谱的频点分别为 211.46 Hz, 522.65 Hz, 796.98 Hz。

为进一步探究深度学习模型的线谱增强性能,

选取传统方法 WF 与 Mapping、Masking 模型的增强结果进行对比分析, 测试数据与上述深度模型相同, 时频谱的 FFT 点数为 2048, WF 的增强结果如图 5(c)(f) 所示。Mapping 和 Masking 模型单线谱和三线谱的增强结果如图 6(c)(f) 与图 7(c)(f) 所示。对比图 5—图 7 可以看出, 深度学习模型增强效果明显优于 WF 增强效果。统计 8000 组测试集线谱增强结果, 其中 WF 的平均增益为 4.77 dB, Mapping 的平均增益为 11.74 dB, Masking 平均降噪结果为 7.52 dB。

由图 6 和图 7 可见, 深度学习 Mapping 模型和 Masking 模型均具备对仿真数据单线谱和三线谱的增强能力。分析 Mapping 模型和 Masking 模型对线谱增强的机制, 以双线谱测试数据结果的频域剖面图为例, 其频点分别为 250.07 Hz 和 367.21 Hz, 见图 8。

从图 8(b)(d) 可以看出, Mapping 模型增强含噪样本后, 直接抬高了线谱的能量值, 而对自身样本噪

底的抑制性不大。Masking 模型则在保持线谱本身能量的基础上, 整体降低了噪声。另外, 从线谱增强的绝对值看, Mapping 优于 Masking, Mapping 对线谱的增益大约为 12 dB 左右, 而 Masking 对于噪声的抑制大约在 7 dB 左右。但是, 对比含噪线谱和增强后的线谱可以发现, Mapping 模型增强后的线谱相对于含噪线谱存在畸变现象, 而 Masking 模型很好地保留了含噪线谱的特性, 这与第 3 节对模型训练特征的分析相符。

实际目标低频线谱通常不止三根, 由于水下环境复杂, 将线谱数量作为分类标准较为繁琐, 所有结果均进行展示也会过于冗长, 因此本文将三根以上的频谱统一称为“多线谱”。多线谱缩短了线谱之间的间距, 更加符合实际数据的复杂情况, 在此使用上述训练好的模型对多线谱数据进行增强, 以研究 Masking 模型对邻近线谱的增强能力。四线谱和六




图 5 WF 常规目标线谱增强结果 (a) 静止目标仿真单线谱; (b) 加噪后单线谱; (c) WF 输出单线谱; (d) 静止目标仿真三线谱; (e) 加噪后三线谱; (f) WF 输出三线谱




图 6 Mapping 模型常规目标线谱增强的结果 (a) 静止目标仿真单线谱; (b) 加噪后单线谱; (c) Mapping 模型输出单线谱; (d) 静止目标仿真三线谱; (e) 加噪后三线谱; (f) Mapping 模型输出三线谱




图7 Masking 模型常规目标线谱增强的结果 (a) 静止目标仿真单线谱; (b) 加噪后单线谱; (c) Masking 模型输出单线谱; (d) 静止目标仿真三线谱; (e) 加噪后三线谱; (f) Masking 模型输出三线谱




图8 双线谱案例频域剖面图 (a) 案例1, 加噪后双线谱; (b) 案例1, Mapping 模型输出双线谱; (c) 案例2, 加噪后双线谱; (d) 案例2, Masking 模型输出双线谱

线谱的部分结果如图9所示, 四线谱的线谱频点分别为 118.85 Hz, 154.94 Hz, 417.98 Hz, 590.04 Hz, 六线谱的线谱频点分别为 115.46 Hz, 217.76 Hz, 231.3 Hz, 485.89 Hz, 604.66 Hz, 819.19 Hz。

从图9(a)(d)可以看出, 原线谱存在极为邻近的线谱, 后者线谱频点之间频率相差小于 30 Hz。从图9(c)(f)可以看出, Masking 模型不会混淆邻近线谱,

Masking 对多线谱平均降噪 7.64 dB。

3.2 运动目标仿真数据实验结果

水下目标辐射噪声测量过程中, 目标工况变化、噪声传播过程中的时空变性等因素, 会导致线谱被噪声淹没或者出现多普勒频移^[21]。为进一步研究上述两种模型对机动目标线谱的增强能力, 模拟水下




图9 Masking模型常规目标多线谱增强的结果 (a) 静止目标仿真四线谱; (b) 加噪后四线谱; (c) Masking模型输出四线谱; (d) 静止目标仿真六线谱; (e) 加噪后六线谱; (f) Masking模型输出六线谱

运动目标的仿真数据进行实验。仿真目标环境为二维平面匀速运动, 由于多普勒频移和相对运动速度有关, 为了能够在频谱上看到明显的多普勒频移, 目标运动航速设置为 20 m/s, 目标运动方向为 45° , 目标初始位置位于原点方位 180° , 距离为 6000 m, 目标区域水深为 1500 m, 目标深度为 10 m, 运动时间为 500 s, 水听器位于水面, 即水听器水深为 0 m。仿真态势图以及方位角度和目标距离分别如图 10 和图 11 所示。

仿真线谱采样频率为 4000 Hz, 信噪比为 -35 dB, 线谱初始频点为 130 Hz, 283 Hz, 388 Hz, 多普勒频移主要由运动目标与水听器之间的相对运动产生, 由于水听器静止, 多普勒频移为

$$f_D = \frac{v_s}{v \pm v_s} f, \quad (11)$$

式中, f 表示发射源初始频率; v 表示声波在水中的运动速度, 约为 1500 m/s; v_s 表示运动目标相对与介质的移动速度, 正负号代表相对运动方向。上述运动目标仿真事件产生的多普勒频移如图 12 所示, 时频谱

图与加噪结果如图 13 所示, WF、Mapping 和 Masking 模型的增强结果如图 14 所示。

从图 13 和图 14 可以看出, 由于目标与水听器的相对运动, 线谱存在多普勒频移, Mapping 和 Masking 模型均可训练具有多普勒频移的线谱, 其整体增强结果均优于传统 WF 方法, Mapping 对具有多




图10 仿真态势图




图11 目标方位和距离随时间变化情况 (a) 目标方位; (b) 目标距离




图 12 运动目标仿真数据多普勒频移




图 13 仿真运动目标时频图 (a) 加噪前; (b) 加噪后

普勒频移的线谱增强 10.17 dB, Masking 对具有多普勒频移的线谱降噪 8.33 dB。

3.3 SWellEx-96 海试数据实验结果

使用 SWellEx-96 公开数据集验证本文提出的两种深度学习模型对于真实环境中目标线谱增强的可行性。SWellEx-96 公开数据采集于 1996 年, 实验中部署的声学传感器包括 1 个垂直线阵列 (VLA)、1 个倾斜线阵列 (TLA) 以及 2 个水平线阵列 (HLA), 数据集采样频率为 1500 Hz, 包含事件 S5 数据、事件 S59 数据和详细的声源信息数据, 事件 S5 无大型干扰, 而事件 S59 在整个事件期间均有一艘水面舰艇进行声源干扰, 该数据集详见 <http://swellex96.ucsd.edu>。

分别使用 S5 和 S59 中 VLA 接收通道 1 中持续 7200 s 的数据进行验证, 仅展示前 1200 s 的线谱增强结果, 态势图如图 15 所示。使用传统 WF 方法对 SWellEx-96 数据进行增强, 结果如图 16 所示。从图 16(c)(d) 可以看出, 对于 SWellEx-96 海试数据, S59 事件中多普勒频移较小, 传统方法 WF 无法识别, 直接拉直了整根线谱, 破坏了线谱的多普勒频移




图 14 WF、Mapping 和 Masking 模型对运动目标线谱的增强结果 (a) WF 方法; (b) Mapping 模型; (c) Masking 模型




图 15 S5 和 S59 事件态势图 (前 1200 s)

性质, 此外由于实际数据线谱信噪比较低, WF 直接降低了部分线谱的能量, 导致线谱整体失真。

由于 Mapping 模型学习特征为仿真频谱的映射关系, 并且在训练阶段只训练了单线谱、双线谱和三线谱, 没有对其添加色噪声数据进行训练, 对于 SWellEx-96 实验数据中存在环境色噪声与多线谱 (线谱数量随机) 的增强不满足本文提出的不失真特性, 其增强结果如图 17 所示。相较于 Mapping 模型, Masking 模型具有良好的不失真性质, Masking 增强结果如图 18 所示。由图 18 可见, S5 事件在 0~1200 s 线谱均较为稳定, 线谱含多普勒频移较小且噪声较小。S59 事件如红色虚线框所示, 在 0~400 s 存在明显的多普勒频移, 且背景噪声更大, 这与实际试验情况相符。对比图 18(c)(d) 可以发现, Masking 模型对存在多普勒频移的实际海试数据也具有线谱降噪能




图 16 SWellEx-96 数据 WF 增强结果 (a) S5 事件频谱; (b) S5 事件 WF 输出结果; (c) S59 事件频谱; (d) S59 事件 WF 输出结果




图 17 SWellEx-96 数据 Mapping 模型增强结果 (a) S5 事件频谱; (b) S5 事件 Mapping 模型输出结果; (c) S59 事件频谱; (d) S59 事件 Mapping 模型输出结果




图 18 SWellEx-96 数据 Masking 模型增强结果 (a) S5 事件频谱; (b) S5 事件 Masking 模型输出结果; (c) S59 事件频谱; (d) S59 事件 Masking 模型输出结果

力, 该模型在不破坏线谱本身的基础上能够对背景噪声降低 7.87 dB。

4 结论

运动声源线谱存在低信噪比、多普勒频移等情况, 传统增强方法受信噪比影响较大且只能处理非

线性噪声, 本文提出了有监督的深度学习方法, 利用 Mapping 模型和 Masking 模型实现了对运动声源线谱的增强。对于目标仿真数据以及 SWellEx-96 海试数据, Mapping 和 Masking 模型均展现出有效的线谱增强能力, 优于传统 WF 方法。Masking 模型较 Mapping 模型在保持线谱不失真方面表现更佳。对于静止目标仿真数据, 在 -35 dB 信噪比下, Masking 模型能平

均增益线谱 11.74 dB 并降噪 7.52 dB。对于运动目标,两者都能有效增强多普勒频移线谱,Masking 平均降噪 8.33 dB。对于 SWellEx-96 海试数据,Masking 模型同样保持了良好的不失真降噪特性,对存在多普勒频移的线谱背景噪声降低达 7.87 dB,验证了其在实际应用中的可靠性。

与传统的线谱增强方法相比,本文提出的基于深度学习的线谱增强方法不必建立噪声滤波器模型,且本地可生成足够的训练样本使模型充分利用线谱与噪声的特征量之间的差异,获得更好的线谱增强效果。然而,深度学习模型需要大量的标签数据,且需选择合适的特征构建和训练模型,如果深度学习模型的数据特征参数选取不合理或样本数量不足,则会降低线谱增强能力和泛化性。

参 考 文 献

- 1 金盛龙,迟骋,李宇,等.稀疏驱动自适应线谱增强的水下目标谱熵检测. *声学学报*, 2021; **46**(6): 1059–1069
- 2 Zhang J, Li Y, Ali W, *et al.* Line spectrum enhancement of underwater acoustic signals using Kalman filter. *J. Marine Sci. Appl.*, 2020; **19**: 148–154
- 3 杜栓平,陈越超,罗兆瑞.利用深层卷积网络自适应增强学习的水声目标线谱提取方法. *声学学报*, 2023; **48**(4): 699–714
- 4 李启虎.用于拖曳式线列阵的一种新的线谱增强系统. *声学学报*, 1988; **13**(3): 167–173
- 5 Hao Y, Chi C, Qiu L, *et al.* Sparsity-based adaptive line enhancer for passive sonars. *IET Radar Sonar Navig.*, 2019; **13**(10): 1796–1804
- 6 纳杰斯,王心怡.迭代维纳滤波在水声信号分离中的应用. *舰船电子工程*, 2016; **36**(11): 131–134
- 7 Ju D, Chi C, Li Z, *et al.* Deep-learning-based line enhancer for passive sonar systems. *IET Radar Sonar Navig.*, 2022; **16**(3): 589–601
- 8 薛灵芝,曾向阳,杨爽.基于生成对抗网络的水声目标识别算法. *兵工学报*, 2021; **42**(11): 2444–2452
- 9 Liang Q, Shi D, Wang Q, *et al.* Shock resistance simulation in time domain and experiment study for the hung condenser. INTER-NOISE and NOISE-CON Congress and Conference Proceedings, Institute of Noise Control Engineering, San Francisco, CA, 2015: 827–838
- 10 Han W, Zhang X, Min G, *et al.* A novel single channel speech enhancement based on joint Deep Neural Network and Wiener Filter. IEEE International Conference on Progress in Informatics and Computing, IEEE, Nanjing, China, 2015
- 11 Baby D, Verhulst S. Biophysically-inspired features improve the generalizability of neural network-based speech enhancement systems. Interspeech, ISCA, Hyderabad, India, 2018
- 12 Takeuchi D, Yatabe K, Koizumi Y, *et al.* Invertible DNN-based nonlinear time-frequency transform for speech enhancement. IEEE International Conference on Acoustics, Speech and Signal Processing, Barcelona, Spain, 2020: 6644–6648
- 13 鞠东豪,迟骋,李宇,等.基于无监督深度学习的线谱增强算法. *舰船科学技术*, 2020; **42**(23): 117–120
- 14 Xu Y, Du J, Dai L R, *et al.* A regression approach to speech enhancement based on deep neural networks. *IEEE/ACM Trans. Audio Speech Lang. Process.*, 2015; **23**(1): 7–19
- 15 Du J, Huo Q. A speech enhancement approach using piecewise linear approximation of an explicit model of environmental distortions. Interspeech, ISCA, Brisbane, Australia, 2008
- 16 Delfarah M, Wang D L. Features for masking-based monaural speech separation in reverberant conditions. *IEEE/ACM Trans. Audio Speech Lang. Process.*, 2017; **25**(5): 1085–1094
- 17 Wang Y, Narayanan A, Wang D L. On training targets for supervised speech separation. *IEEE/ACM Trans. Audio Speech Lang. Process.*, 2014; **22**(12): 1849–1858
- 18 李启虎,李敏,杨秀庭.水下目标辐射噪声中单频信号分量的检测:理论分析. *声学学报*, 2008; **33**(3): 193–196
- 19 Guo W, Piao S, Yang T C, *et al.* High-resolution power spectral estimation method using deconvolution. *IEEE J. Oceanic Eng.*, 2020; **45**(2): 489–499
- 20 Hao Y, Chi C, Liang G. Sparsity-driven adaptive enhancement of underwater acoustic tonals for passive sonars. *J. Acoust. Soc. Am.*, 2020; **147**(4): 2192–2204
- 21 赵颖楠,张阳,彭占立.基于运动平台的多普勒频移无源定位算法. *舰船电子对抗*, 2023; **46**(2): 45–46