

基于动态参数HMM的水声信号线谱轨迹提取方法

罗昕炜^{*①} 李 磊^① 沈子涵^②

^①(东南大学水声信号处理教育部重点实验室 南京 210096)

^②(航空工业沈阳飞机设计研究所 沈阳 110035)

摘 要: 针对传统隐马尔可夫模型(HMM)方法提取时变线谱与多线谱的能力较弱以及动态规划过程计算量过大的问题, 该文提出一种基于动态参数的1维隐马尔可夫模型(1D-HMM)的方法用于水声信号低频分析与记录(LOFAR)图中的线谱轨迹提取。该方法将时变频率状态建模为1阶马尔可夫过程, 利用Viterbi算法循环提取多条线谱轨迹。在动态规划的迭代过程中, 通过实时计算序列的1阶导数动态调整HMM中的状态转移概率矩阵, 提升了对线谱轨迹的提取能力和多线谱的分辨能力; 设计了一种基于动态滑动窗口的功率谱累积方法估计线谱的生灭, 剔除虚假的线谱轨迹并判断线谱轨迹提取的结束。同时, 该方法在实现过程中设计了对LOFAR图数据的块处理策略, 大大减少了计算量。仿真和实际数据的处理结果表明, 该方法在低信噪比条件下能够有效地检测和跟踪复杂时变频谱的频率状态, 并有较好运行效率, 为声呐设备的弱信号检测提供了良好的技术支持。

关键词: 线谱轨迹提取; 频率轨迹; 隐马尔可夫模型; 动态搜索

中图分类号: TN911.7

文献标识码: A

文章编号: 1009-5896(2022)06-1956-10

DOI: [10.11999/JEIT211374](https://doi.org/10.11999/JEIT211374)

Line Spectrum Trajectory Extraction Method of Underwater Acoustic Signal Based on Dynamic Parameter HMM

LUO Xinwei^① LI Lei^① SHEN Zihan^②

^①(Key Laboratory of Underwater Acoustic Signal Processing, Ministry of Education, Southeast University, Nanjing 210096, China)

^②(Shenyang Aircraft Design and Research Institute, Shenyang 110035, China)

Abstract: In view of the weak ability of traditional Hidden Markov model (HMM) method to extract time-varying line spectrum and multi line spectrum and the large amount of calculation in dynamic programming process, a One- Dimensional Hidden Markov Model (1D-HMM) method based on dynamic parameters is proposed to extract line spectrum trajectory in LOw Frequency Analysis and Recording (LOFAR) diagram of underwater acoustic signal. In this method, the time-varying frequency state is modeled as a first-order Markov process, and the Viterbi algorithm is repeated several times to extract multiple frequency trajectories with the largest a posteriori probability. In the iterative process, the state transition probability matrix in HMM is dynamically adjusted by the first derivative of the sequence calculated in real time, which improves the extraction ability of line spectrum trajectory and the resolution ability of multi line spectrum; A power spectrum accumulation method based on dynamic sliding window is designed to estimate the birth and death of line spectrum and eliminate false line spectrum trajectories. At the same time, the block processing strategy is designed for LOFAR graph data in the implementation process, which reduces greatly the amount of calculation. The simulation and actual data processing results show that the method can effectively detect and track the frequency state of complex time-varying spectrum with good operational efficiency under low signal-to-noise ratio conditions, which provides good technical support for the detection of weak signals in sonar devices.

收稿日期: 2021-11-30; 改回日期: 2022-03-12; 网络出版: 2022-03-26

*通信作者: 罗昕炜 luoxinwei@seu.edu.cn

基金项目: 国家自然科学基金(12174053, 91938203), 中央高校基本科研业务费专项基金(2242021k30019)

Foundation Items: The National Natural Science Foundation of China (12174053, 91938203), The Fundamental Research Funds for the Central Universities (2242021k30019)

Key words: Line spectrum detection and tracking; Frequency trajectory; Hidden Markov Model (HMM); Dynamic search

1 引言

随着人类在海洋中的活动日益频繁, 水下目标的检测与感知已成为海洋信息领域的研究热点。由于声音在水下比电磁波具有更好的传播性能, 声呐系统被广泛应用于水下目标的探测、识别和定位。海洋环境噪声的成分复杂多样, 包括地震噪声、船舶噪声、波浪噪声、热噪声、生物噪声等。本文的主要目的是在水下声环境中提取窄带信号的线谱轨迹。

在被动声呐接收到的各种水声信号中, 窄带信号通常是由人工设备或机械部件的往复运动产生的。船舶辐射噪声中的低频信号窄带线谱具有强度高、稳定性好、传播损耗低等特点, 是当前水下目标探测的主要依据之一^[1-3]。窄带信号可以指示目标的存在性并反映目标的状态。在多帧功率谱构成的低频分析与记录(LOW Frequency Analysis and Recording, LOFAR)图中, 稳定的窄带信号将形成一条亮线, 即线谱轨迹。因此, LOFAR图线谱轨迹的提取对于低噪声、安静水下目标的检测、跟踪和分类具有重要意义。LOFAR图中的线谱轨迹提取必须考虑两种类型的线谱^[4]。第1类线谱具有恒定的频率, 但多普勒频移随时间而发生, 频率变化可以用确定的运动模型来描述。因此, 目标运动分析方法可用于轨迹提取。联合概率数据关联方法^[5,6]和多概率假设方法^[7]都可以在线谱上实现良好的跟踪效果, 并且具有较高的计算效率。第2类线谱没有明确的运动模型, 其频率变化表现为随机运动。在这种情况下, 基于隐马尔可夫模型(Hidden Markov Model, HMM)的动态规划算法具有良好的检测性能。文献^[8,9]提出一种基于HMM的以阈值判断后的LOFAR图作为输入的单线谱跟踪器。文献^[10-12]以提取两个线谱为例, 通过增加HMM状态变量的维数, 提出了一种多线谱检测方法, 但算法复杂度呈指数增长。此外, 文献^[13]指出, 不需要增加状态变量的维数, 而是通过多次跟踪单线谱来提取LOFAR图中的线谱轨迹, 可以大大降低算法复杂度, 并保持检测性能。因此, 多次连续提取单线谱的方法得到了广泛的应用。

此外, 将线谱的运动模型与隐马尔可夫模型相结合, 还可以实现对第1类线谱的有效提取。文献^[14]提供了多个线谱变化模型和相应的构造HMM状态变量的方法, 并通过选择最佳线谱模型来提高线谱检测的性能。文献^[4,15]使用2维状态变量对线谱频率及其变化率进行建模, 并给出了一种不需要

先验信噪比信息的线谱跟踪方法。在文献^[4,14,15]中, 2维状态变量建模能够适应更复杂的线性频谱变化, 具有更好的适应性, 但此时检测算法的计算复杂度也大大增加, 难以满足实际应用的需求。文献^[16-18]都引入了块处理框架来估计频率状态序列的1阶导数和2阶导数, 以减少状态变量的维数和计算负担。然而, 在单块线谱轨迹过程中, 估计的1阶导数和2阶导数仍然是常数, 这可能导致模型失配。

在此背景下, 本文提出了一种基于动态转移概率矩阵1维隐马尔可夫模型的线谱检测算法, 用于LOFAR图中的线谱轨迹提取。该方法的创新点在以下3方面: (1)引入具有动态转移概率矩阵的1维隐马尔可夫模型, 提高了算法对复杂线谱变化的适应性以及在线谱检测中的性能; (2)提出了一种基于动态滑动窗口的功率谱累积方法, 提高线谱生灭的估计能力; (3)设计了块处理框架, 大大提升了算法的处理效率。仿真数据和实测数据的实验分析表明了本文方法在线谱轨迹提取能力和算法效率方面均达到较好的性能。

2 信号模型与参数

HMM是一种统计模型, 它用来描述一个含有隐含未知参数的马尔可夫过程。HMM表现为一个结构简单的动态贝叶斯网络, 在时序数据的建模、语音识别、水声识别^[19]等领域有着广泛的应用。水声信号中的窄带成分可以刻画为在时频空间持续的线谱轨迹, 在对水声信号时频分析获得的LOFAR图中, 窄带成分表现为噪声背景下的时频亮点序列。HMM模型的隐藏状态、观测值和相邻时刻的状态变化可以较好地刻画水声信号窄带成分。

2.1 HMM的基本要素

HMM包含一组隐藏状态和一组观测值。每个隐藏状态都与概率分布相关联, 隐藏状态之间的转移由转移概率控制。隐藏状态可以根据其相应的观测概率分布生成观测值。但HMM中的隐藏状态是不可观察的, 只能通过观测值来估计。通过以下参数, 可以完全描述一个HMM。

$Q = \{q_1, q_2, \dots, q_N\}$ 是隐藏状态集合, 其中, N 是可能的隐藏状态的数量;

$V = \{v_1, v_2, \dots, v_M\}$ 是观测值集合, 其中, M 是观测值的数量;

$A = [a_{i,j}]_{N \times N}$ 是转移概率矩阵, 其中, $a_{i,j} = P_r(q_j \text{ at } k+1 | q_i \text{ at } k)$, k 是离散时间序号, at $k+1$ 表示在 $k+1$ 时刻, at k 表示在 k 时刻;

$B = [b_j(m)]_{N \times M}$ 是观测状态概率矩阵, 其中, $b_j(m) = P_r(v_m \text{ at } k | q_j \text{ at } k)$;

$\Pi = [\pi(i)]_N$ 是马尔可夫链的初始状态概率向量, 其中, $(i) = P_r(q_i \text{ at } k = 1)$;

对于长度为 K 的序列, 对应的隐藏状态序列是 $X = \{x_1, x_2, \dots, x_K\}, x_k \in Q$ 。观测序列定义为 $Z = \{z_1, z_2, \dots, z_K\}, z_k \in V$ 。本文将水声信号的线谱轨迹作为模型的隐藏状态序列 X , 将采样数据进行时频变换处理得到的 LOFAR 图作为观测值 Z 。通过对 LOFAR 图数据的动态规划处理, 可以找出线谱隐藏频率状态序列 X 。在 HMM 理论中, 给定序列 Z 和相应的 HMM 参数 $\{A, B, \Pi\}$, Viterbi 算法^[9] 的估计结果 $\hat{X} = \arg \max_X \{P_r(X|Z)\}$ 具有全局最优解的意义。

2.2 HMM 的参数赋值

马尔可夫过程描述了一个具有离散状态的随机模型, 因此对水声窄带信号建模时需要将信号的频率进行离散化的表示。为了使线谱频率与 LOFAR 图中的时频点对应, 信号频率可以离散到傅里叶变换(DFT)对应的频点上。假设 DFT 将整个频带分成 N 个等间隔频率区间, 第 i 个状态对应的频率区间表示为 $[f_i, f_{i+1}], i = 1, 2, \dots, N$ 。当线谱频率 f 满足 $f_i \leq f < f_{i+1}, i = 1, 2, \dots, N$ 时, 将此时的频点隐藏状态记为状态 i 。即将离散频率作为隐藏状态, 隐藏状态集空间为

$$Q = \{i, \text{ s.t. } i\Delta f \in F^N\} \quad (1)$$

其中, Δf 是 DFT 分析时的频率分辨率, F^N 是 DFT 分析时的离散频率点对应的频率值集合。

相应地, 将数据时频分析得到的第 k 段功率谱输出结果 z_k 作为此时刻对应的观测值

$$z_k = (z_{k,0}, z_{k,1}, z_{k,N-1}) \quad (2)$$

其中, $z_{k,i} = \sqrt{P_k(i)/N}, i \in Q$, $P_k(i)$ 为第 k 段功率谱中第 i 个频段的功率谱值。此时, 观测值序列为 $Z = \{z_1, z_2, \dots, z_K\}$ 。

HMM 中的初始状态概率向量 π 决定了线谱检测与跟踪的初始状态, 当没有任何跟踪线谱的先验信息时, 可假定初始状态向量 π 服从均匀分布, 有

$$\pi(i) = \frac{1}{N} \quad (3)$$

观测概率矩阵 B 中的元素为

$$b_i(z_k) = P_r(z_k | q_k = i) \quad (4)$$

表示第 k 段数据对应的隐藏状态为 i 时, 观测值为 z_k 的概率。根据文献^[20], B 中元素可由式(5)计算

$$b_i(z_k) = \frac{z_{k,i}}{\sum_{j=1}^N z_{k,j}} \quad (5)$$

马尔可夫链的转移概率是在给定时刻 k 的频率状态的条件下, $k+1$ 时刻频率状态的概率。频率状态变化可建模如下3种模型:

(1) 线谱频率基本稳定时, 线谱频率的1阶导数接近0。状态转移满足 $q_{k+1} = q_k + W_k$, 其中, 隐藏状态 $q_k = f_k/\Delta f$ 是1维的。 W_k 是零均值高斯白噪声 $N(0, \sigma_W)$, σ_W 取决于信噪比及线谱频率的稳定性。

(2) 线谱频率随时间线性变化时, 线谱频率的1阶导数是确定的斜率 $\dot{q}$ 。状态转移满足 $q_{k+1} = q_k + \dot{q} + W_k$, 隐藏状态 $q_k = f_k/\Delta f$ 也是1维的。

(3) 当线谱频率变化率不恒定时, 线谱频率的1阶导数也随时间变化, 需要用2维隐藏状态来表述。它包括两个变量: 频率及其1阶导数, 即 $q_k = [f_k/\Delta f \quad \dot{f}_k/\Delta f]^T$, 其中, $\Delta \dot{f} = \Delta f^2 \epsilon$, ϵ 表示1阶导数的权重。在这种情况下, 状态转换可以描述为

$$q_k = H q_{k-1} + W_k \quad (6)$$

其中, 矩阵 $H = \begin{bmatrix} 1 & \epsilon \\ 0 & 1 \end{bmatrix}$, W_k 是零均值的加性噪声, 其协方差矩阵通常选择为

$$R = \chi \begin{bmatrix} \frac{1}{3} & \frac{1}{2\epsilon} \\ \frac{1}{2\epsilon} & \frac{1}{\epsilon^2} \end{bmatrix} \quad (7)$$

对于模型(1), 转移概率密度函数为

$$P_r(q_{k+1}|q_k) = N(q_{k+1}; q_k, \sigma_W) \quad (8)$$

其中, $N(q_{k+1}; q_k, \sigma_W)$ 表示 q_{k+1} 服从均值为 q_k 、方差为 σ_W 的高斯分布, 因此得到线谱点频率从状态 i 转移到状态 j 的概率为

$$\begin{aligned} g_{ij} &= P_r(q_{k+1} = j | q_k = i) \\ &= \frac{1}{\sqrt{2\pi\sigma_W}} \exp\left(-\frac{(f_j - f_i)^2}{2\sigma_W^2}\right), \\ i, j &> 0, |f_i - f_j| \leq G \end{aligned} \quad (9)$$

其中, G 为预先设置的偏移范围。在实际过程中, 相邻时刻的线谱频率变化是在一定范围内的, 默认频率变化超过 G 的概率为0。归一化后得到矩阵 A 中元素的计算公式, 即

$$a_{i,j} = \frac{g_{ij}}{\sum_{k=1}^N g_{ik}}, \quad i, j = 1, 2, \dots, N \quad (10)$$

类似地, 对于模型(2), 转移概率密度函数为

$$P_r(q_{k+1}|q_k) = N(q_{k+1}; q_k + \dot{q}, \sigma_W) \quad (11)$$

在这种情况下, 只要知道恒定变化速率 $\dot{q}$ 的值, 状态转移矩阵 A 就可以通过式(9)、式(10)计算。

对于模型(3), 转移概率密度函数为

$$P_r(q_{k+1}|q_k) = \frac{\Omega}{2\pi\sqrt{\det \mathbf{R}}} \exp\left(-\frac{1}{2}q_k - \mathbf{H}q_{k-1}^2 \mathbf{R}^{-1}\right) \quad (12)$$

其中, Ω 是使矩阵 $\mathbf{A}$ 中每列之和为1的归一化常数。状态转移矩阵 $\mathbf{A}$ 的值也可根据式(10)计算。

在3种基本模型中, 模型(1)和模型(2)采用1维隐藏状态空间, 仅适用于线谱频率具有确定性1阶导数的情况。模型(3)使用2维隐藏状态空间, 虽然可以匹配复杂线谱变化的情况, 但由于引入了1阶导数维数, 大大增加了算法的计算复杂度。由此, 对模型(3)进行改进, 其转移概率密度函数定义如下

$$P_r(q_{k+1}|q_k) = N(q_{k+1}; q_k + \dot{q}_k, \sigma_W) \quad (13)$$

与模型(2)的确定性1阶导数不同, 这里的 $\dot{q}_k$ 随时间变化。本文将Viterbi算法与线性最小二乘拟合方法相结合, 估计在 k 时刻对应于每个频率状态的导数 $\dot{q}_k$ 。

当信号轨迹随时间快速变化时, 由于模型(1)和模型(2)的矩阵 $\mathbf{A}$ 在线谱跟踪之前已确定, 跟踪过程中无法修改, 性能将急剧下降。对于模型(3), 虽然将隐藏状态空间扩展到2维可以更准确地跟踪复杂信号, 但计算复杂度从 $O(kN^2)$ 增加到 $O(kM^2N^2)$ (M 是1阶导数的状态数), 这大大提高了计算量, 难以满足应用需求。相比之下, 所提出的改进模型更适合复杂多变的实际情况。实时估计1阶导数 $\dot{q}_k$, 使矩阵 $\mathbf{A}$ 随线谱频率状态的变化而动态调整, 且该方法仅需要1维状态空间, 计算量小。

3 线谱轨迹提取方法与实现

3.1 处理框架

基于HMM的动态规划方法在检测LOFAR图中的线谱时, 计算量与隐藏状态数呈平方关系。如果同时检测功率谱中的所有频率状态, 则计算量非常大。针对上述问题, 在线谱轨迹提取的过程中设计了分块处理的框架, 将LOFAR图分成小的时频数据块分别进行线谱轨迹提取, 再将所提取的线谱轨迹进行融合得到整个时频空间的线谱轨迹结果。基于分块处理的线谱轨迹提取方法的框架如图1所示。

整个线谱轨迹提取可分为3个步骤: 数据分块预处理、单块数据线谱轨迹提取和多线谱轨迹融合。

3.2 单块线谱轨迹提取

在单数据块线谱轨迹提取过程中, 将HMM与频率状态变化模型相结合, 在HMM的框架下设计基于动态参数线谱轨迹提取和生灭判断的方法。图2为单块数据线谱轨迹提取算法的流程图。

处理流程中包括参数初始化、轨迹提取、生灭判断和数据更新几个过程。

步骤1 参数初始化。根据2.2节, 利用获得的功率谱设置隐马尔可夫模型的参数, 计算矩阵 $\mathbf{A}$ 的初始化元素 $a_{j,i}$ 。使用Viterbi算法估计线谱信息时, 需要定义两个递归变量:

在状态 $q_k = i$ 时, 所有可能的状态时间序列 $q_1 \rightarrow q_2 \rightarrow \dots \rightarrow q_k$ 中, 最大概率的序列对应的概率值定义为

$$\delta_k(i) = \max_{q_1, q_2, \dots, q_{k-1}} P(q_k = i, q_1, q_2, \dots, q_{k-1}, z_k, z_{k-1}, \dots, z_1) \quad (14)$$

其中, $i = 1, 2, \dots, N$ 。

在状态 $q_k = i$ 时, 概率最大的状态时间序列 $q_1 \rightarrow q_2 \rightarrow \dots \rightarrow q_k$ 中, 第 $k-1$ 个时刻的隐藏状态 q_{k-1} 的值, 定义为

$$\eta_k(i) = \arg \max_j [\delta_{k-1}(j) a_{j,i}] \quad (15)$$

其中, $1 \leq j \leq N$ 。

步骤2 轨迹提取。在从时间1到时间 K 提取具有最大后验概率的离散状态序列。用于使用线性最小二乘拟合方法估计线谱频率1阶导数的数据点数量定义为 L_1 。将上述两个局部变量初始化为

$$\left. \begin{aligned} \delta_1(i) &= \Pi(i) b_i^s(z_1) \\ \eta_1(i) &= 0 \end{aligned} \right\} \quad (16)$$

对于 $k = 2, 3, \dots, K$ 时的每个状态 i , 计算 $\delta_k(i)$ 并递归存储其先前状态 $\eta_k(i)$




图1 基于分块处理的线谱轨迹提取框架




图2 基于动态参数的线谱检测流程图

$$\left. \begin{aligned} \delta_k(i) &= \max_j [\delta_{k-1}(j) a_{j,i}^{k-1}] b_i^s(z_k), 1 \leq i, j \leq N \\ \eta_k(i) &= \arg \max_j [\delta_{k-1}(j) a_{j,i}^{k-1}], 1 \leq i, j \leq N \end{aligned} \right\} \quad (17)$$

其中, $a_{j,i}^k$ 是矩阵 $\mathbf{A}$ 中元素在时间 k 时的值, 当 $k < L_1$ 时, 默认 $a_{j,i}^k = a_{j,i}$ 。

用线性最小二乘法预测当 $k \geq L_1$ 时线谱频率的1阶导数 $\dot{q}_k$ 。在时间 k 时, 频率状态通过 $\eta_k(i)$ 进行回溯, 并获得长度为 L_1 的回溯状态序列 $(i, \eta_k(i), \eta_{k-1}(\eta_k(i)), \dots)$ 。在这里, 本文定义了从时间 $k-L_1+1$ 到时间 k , 对应于状态 i 的序列是 $(q_{k-L_1+1}^i, q_{k-L_1+2}^i, \dots, q_k^i)$, 用于估计 $\dot{q}_k^i$

$$\dot{q}_k^i = \frac{L_1 \sum_{l=0}^{L_1-1} [(k-l) q_{k-l}^i] - \left[\sum_{l=0}^{L_1-1} (k-l) \right] \left(\sum_{l=0}^{L_1-1} q_{k-l}^i \right)}{L_1 \sum_{l=0}^{L_1-1} (k-l)^2 - \left[\sum_{l=0}^{L_1-1} (k-l) \right]^2} \quad (18)$$

在每一个迭代时刻, 利用频率状态1阶导数的实时估计对矩阵 $\mathbf{A}$ 中的元素进行修改。根据式(8)和式(13), 利用 $a_{j,i}^k = a_{j+\dot{q}_k^i, i}$ 动态更新 $\mathbf{A}$ 矩阵, 并重复递归直到时间 K 。根据式(14), 时间 K 的状态估计由最大 $\delta_K(i)$ 确定, 并且通过使用 η_k 中存储的反向状态进行回溯来获得状态的估计时间序列, 即

$$\left. \begin{aligned} \hat{q}_K &= \arg \max_i [\delta_K(i)] \\ \hat{q}_{k-1} &= \eta_k(\hat{q}_k) \end{aligned} \right\} \quad (19)$$

此时, 可以得到线谱轨迹的初步估计结果 $(\hat{q}_1, \hat{q}_2, \dots, \hat{q}_K)$ 。

步骤3 状态时间序列的生灭判断。Viterbi算法提取的线谱轨迹是长度为 K 的离散线谱估计时间序列。它在LOFAR图上表示为从时间1到时间 K 的曲线。但是, 该曲线或者曲线中的一段可能是虚假轨迹, 需要逐点确定提取的状态时间序列的有效性。由于线谱的幅值是功率谱中的极大值, 且具有

稳定性, 可以通过对LOFAR图中 $P_k(\hat{q}_k)$ 幅值相对附近频率点的强度比值判断频率状态 $\hat{q}_k$ 的合理性。

传统的功率谱积累方法可以通过直接计算一个矩形时频窗的能量作为门限设置的依据, 如果窗长时间内线谱变化比较大, 不同帧之间线谱点频率不相等, 这时传统的累积法会出现谱线展宽等问题, 无法达到预期的性能。为了充分利用线谱的稳定性, 本文设计了动态滑动窗口对连续累积的多帧功率谱数据进行处理。首先利用得到的频率状态时间序列对不同时间帧的功率谱进行移位, 然后对多帧功率谱进行累加。累加结果为

$$\tilde{P}_k(i) = \frac{1}{2L_2+1} \sum_{l=-L_2}^{l=L_2} P_{k+l}(i - \hat{q}_k + \hat{q}_{k+l}), 1 \leq i \leq N \quad (20)$$

其中, L_2 是累积窗口长度。在式(20)中, 当检测到的线谱接近LOFAR图的边界时, $P_{k+l}(i - \hat{q}_k + \hat{q}_{k+l})$ 的值被设置为零, 即

$$\begin{aligned} P_{k+l}(i - \hat{q}_k + \hat{q}_{k+l}) &= 0, \\ i - \hat{q}_k + \hat{q}_{k+l} &\notin [1, N] \text{ 或 } k+l \notin [1, K] \end{aligned} \quad (21)$$

从式(20)和式(21)可以看出, 上述操作旨在根据线谱频率的变化动态调整滑动窗口的位置和形状。动态滑动窗口可以提高功率谱累积结果的信噪比, 提高线谱检测性能。图3为动态滑动窗口的示意图。

图3可以看出, 滑动窗口中, 同一轨迹在不同时间帧产生的线谱频点对应的功率谱幅值能够直接相加, 增大了功率谱累积结果的信噪比, 进而提高线谱检测性能。利用 3σ 准则对其进行阈值比较, 获得线谱轨迹点的有效性判断。

步骤4 更新时频块中的数据。提取出单根线谱的时间序列后, 应去除当前时频块中与本次检测状态序列相关的幅值信息。将提取的频率状态相对应的功率谱幅度设置为背景最小值, 更新后的时频块用于下一次线谱提取。重复步骤1—步骤4, 直到提取的状态时间序列中的所有频率状态被步骤4判断为无效, 结束当前块中的线谱提取。




图3 基于滑动窗的线谱轨迹的生灭分析示意图

3.3 多线谱轨迹融合

单块时频数据提取的线谱轨迹是局部时频范围内的轨迹, 进行各时频块之间线谱轨迹的融合才能得到完整的轨迹。可采用计算相邻时频块线谱轨迹距离矩阵的方法判决多根线谱轨迹是否为同一轨迹。第 $i-1$ 个时频块和第 i 个时频块之间距离矩阵 $J_{i-1,i}$ 定义为

$$J_{i-1,i} = \begin{bmatrix} \Delta_{11} & \Delta_{12} & \cdots & \Delta_{1G_i} \\ \Delta_{21} & \Delta_{22} & \cdots & \Delta_{2G_i} \\ \vdots & \vdots & \ddots & \vdots \\ \Delta_{G_{i-1}1} & \Delta_{G_{i-1}2} & \cdots & \Delta_{G_{i-1}G_i} \end{bmatrix} \quad (22)$$

其中, G_i 是第 i 个时频块检测到的线谱数目。矩阵 $J_{i-1,i}$ 中的元素 $\Delta_{j,r}$ 表示第 $i-1$ 个时频块中第 j 根线谱和第 i 个时频块中第 r 根轨迹的距离, 定义为

$$\Delta_{j,r} = \frac{\sum_{s=1}^{N_s} \left(\left| f_{i-1}^j(k_s) - f_i^r(k_s) \right| \right)}{N_s} \quad (23)$$

其中, 变量 N_s 是两个检测到的线谱中相同时间段的线谱点的数量, $f_i^r(k_s)$ 是位于第 i 个块的第 r 条线谱中第 s 个线谱点的频率状态, k_s 是频率状态的时间帧序号。计算出距离矩阵后, 根据矩阵中列和行的最小值判断, 找到最近的线谱对。如果最小距离满足阈值条件, 则认为该线谱对属于同一线谱, 并将两条线谱合并; 否则, 不进行线谱合并。依次对提取的所有轨迹按起止时间和频率进行配对, 最后得到整个观测时频空间完整的线谱轨迹。

4 性能评估

本节利用仿真信号和实测信号对所提出算法性能进行评估, 并与基于1维隐马尔可夫模型和2维隐马尔可夫模型的传统算法进行比较。

4.1 仿真数据测试

仿真信号是在高斯白噪声的背景上添加了5根线谱轨迹, 线谱的宽带信噪比为 -29 dB。这5根线谱轨迹具有不同变化趋势, 其中线谱(1)是频率稳定的轨迹; 线谱(2)和(3)是频率随时间线性变化的调频脉冲信号; 线谱(4)和(5)是存在交叉的线谱轨迹, 具有变化的斜率。待测LOFAR图的频带为 $0 \sim 625$ Hz, 频率分辨率为 1 Hz, 时间分辨率为 1 s。

图4为待检测的LOFAR图与线谱轨迹示意, 以LOFAR图为输入, 将传统的基于1D-HMM和2D-HMM的检测方法以及本文提出的方法用于线谱轨迹提取, 各参数设置如下: 设置每个时频块频率点数为256点, 时间点数为20点; 计算 A 矩阵时, $\sigma_W = 1$, $\epsilon = 1$, $\chi = \sqrt{12}$; 在判断频率状态的生灭时, 3种方法分别采用传统的阈值判断法和提出的自适应滑动窗口累积法。




图4 待检测的LOFAR图与线谱轨迹示意

比较了6种方法对仿真信号的处理结果。这6种方法分别是传统的1D-HMM方法(1D-HMM)^[17]、具有自适应滑动窗口的传统1D-HMM方法(1DW-HMM)、具有动态 A 矩阵1D-HMM方法(DA-HMM)、使用自适应滑动窗口的动态 A 的1D-HMM方法(DAW-HMM)、传统的2D-HMM方法(2D-HMM)和具有自适应滑动窗口的传统2D-HMM方法(2DW-HMM)。图5显示了各种方法的处理结果。

在图5中, 蓝线线条表示线谱的实际位置。“+”表示各种方法检测到的线谱点位置。检测到的点属于相同的线谱轨迹用相同颜色的“+”表示。从图中可以看出, 这6种方法都可以准确提取频率变化较小的线谱, 包括线谱(1)和线谱(2)。线谱(3)—线谱(5)的轨迹由于频率的变化较大或者趋势无法实时估计, 因此基于1D-HMM和1DW-HMM方法在线谱频率快速变化时无法获得完整的线谱轨迹。提出的基于DA-HMM和DAW-HMM方法, 以及2D-HMM和2DW-HMM方法能够很好地适应复杂线谱的变化, 准确地提取出所有的5条线谱。

为了更直观地比较性能, 定义两个变量: 检测概率和虚警概率。

$$PD = \frac{N_d}{N_r} \times 100\% \quad (24)$$

$$PF = \frac{N_i}{N_t} \times 100\% \quad (25)$$

其中, N_d 是被正确检测到的时频点数量, N_r 是真实时频点的数量, N_i 是检测到的虚假时频点数量, N_t 是所有被检测到的时频点数量。 N_r 由信号本身决定, N_d , N_i 和 N_t 由检测方法决定, 且满足 $N_d + N_i = N_t$ 。

这些方法在一台具有8核CPU(I7 9700K)和16GB RAM的PC上进行了测试, 并在MATLAB上实现并运行, 测试模拟数据的时间长度为80 s。每种方法的处理时间和PD, PF如表1所示。

可以看出, 基于DA-HMM/DAW-HMM方法的处理时间与基于1D-HMM/1DW-HMM方法的接近, 且两种方法的计算复杂度相似, 与基于2D-HMM/




图5 6种方法的线谱轨迹提取结果比较

2DW-HMM的方法相比, 该方法的复杂度从 $O(M^2N^2)$ 降低到 $O(N^2)$, 大大降低了计算量, 减少了处理时间。提出的DAW-HMM方法的PD与2DW-HMM方法均达到了较高的检测性能, 且PF与2DW-HMM方法相当, 显著低于其他几种方法。综上DAW-HMM方法在性能和计算效率方面取得了最好的性能指标。

针对3根代表性线谱, 在相同的PF下对基于1D-HMM, DA-HMM和DAW-HMM的3种方法的性能进行比较。其中, 线谱(1)是频率稳定的线谱轨迹; 线谱(2)是频率随时间线性变化的轨迹; 线谱(5)是频率变化率不恒定的线谱轨迹。在不同的信噪比条件下, 首先通过调整阈值使不同方法的PF = 2%, 然后比较检测概率PD。检测概率曲线如图6所示。

表1 不同方法的处理时间和PD, PF

方法	时间 (s)	PD (%)	PF (%)
1D-HMM	13.248	64.05	43.31
1DW-HMM	12.546	70.27	17.41
DA-HMM	16.524	100	10.65
DAW-HMM	14.129	100	1.85
2D-HMM	485.98	100	10.76
2DW-HMM	483.48	100	1.85

从图6可以看出, 传统的1D-HMM缺乏对未知斜率的估计, 对变化的频率轨迹检测性能显著下降。DA-HMM和DAW-HMM的方法可以实时估计线谱频率的1阶导数, 对不同线谱类型保持了较好的性能。进一步, 自适应滑动窗口的使用, 使得DAW-HMM方法取得了最好的检测性能。

4.2 实测数据测试

通过一次湖上试验的数据验证所提出的方法。试验现场的湖水深度约100 m，浮标的水听器被放置在水下15 m的深度，在距离浮标1 km处的同一深度放置了一个声源，距离浮标2 km处的一艘船按照指示航行，如图7所示。

在实验过程中，浮标以4 kHz的采样率对声信号进行采样。在对第1段数据(数据1)进行采样时，声源发出的水下信号包括固定频率的窄带信号和3组LFM脉冲信号，固定频率和LFM信号存在着频率的交叉。在对第2段数据(数据2)进行采样时，声源发出的水下信号包括固定频率的窄带信号和3组线性调频脉冲信号，还包括船舶加速的噪声。

利用DAW-HMM方法对浮标数据进行分析，两段数据的LOFAR图和对应的线谱轨迹提取结果如图8所示。

图8(a)和图8(c)分别是数据1和数据2的LOFAR图。在图8(b)、图8(d)中，提取出的固定频率线谱轨迹用红线标记，频率随时间线性变化的线谱轨迹用蓝线标记，频率变化率不恒定的线谱轨迹用绿线标记。从图中可以看出，DAW-HMM方法可以有

效地检测和区分声源发射的时变线谱和交叉线谱，并正确提取加速船舶产生的漂移线谱。实验结果表明，该方法能有效地提取水声信号中的多种线谱轨迹。

5 结束语

本文提出了一种基于动态参数的HMM的线谱轨迹提取方法DAW-HMM。该方法将目标线谱轨迹建模为1阶隐马尔可夫过程，通过基于动态更新模型参数的动态规划，实现LOFAR图中的线谱估计检测。仿真和实验数据的对比结果表明，该方法通过引入带动态转移概率矩阵的1维隐马尔可夫模型，提高了算法对复杂线谱变化的适应性以及在线谱检测性能；通过动态滑动窗口的功率谱累积方法，提高线谱的生灭的估计能力；所设计的块处理框架，大大提升了算法的处理效率。与传统的基于1维隐马尔可夫模型和2维隐马尔可夫模型的方法相比，本文方法能够高效、准确地提取各种类型的信号线谱，且计算量较小，可以满足声呐系统实时处理的需求，为声呐设备对弱信号的检测和多特征的检测跟踪提供了一种良好的技术途径。




图6 对3根线谱的检测概率对比




图7 实验示意图




图8 数据1、数据2的LOFAR图及线谱轨迹提取结果

参考文献

- [1] 方世良, 杜栓平, 罗昕炜, 等. 水声目标特征分析与识别技术[J]. 中国科学院院刊, 2019, 34(3): 297–305. doi: [10.16418/j.issn.1000-3045.2019.03.007](https://doi.org/10.16418/j.issn.1000-3045.2019.03.007).
FANG Shiliang, DU Shuanping, LUO Xinwei, *et al.* Development of underwater acoustic target feature analysis and recognition technology[J]. *Bulletin of the Chinese Academy of Sciences*, 2019, 34(3): 297–305. doi: [10.16418/j.issn.1000-3045.2019.03.007](https://doi.org/10.16418/j.issn.1000-3045.2019.03.007).
- [2] 马凯, 蔡昱明, 王易川, 等. 基于噪声抑制门的两级自适应线谱增强算法[J]. 电子与信息学报, 2021, 43(3): 773–780. doi: [10.11999/JEIT200540](https://doi.org/10.11999/JEIT200540).
MA Kai, CAI Yuming, WANG Yichuan, *et al.* An algorithm of two-level adaptive line-spectrum enhancement based on noise suppression gate[J]. *Journal of Electronics & Information Technology*, 2021, 43(3): 773–780. doi: [10.11999/JEIT200540](https://doi.org/10.11999/JEIT200540).
- [3] 王学成, 王鲁军, 洪常委. 一种基于DOA分布信息熵加权的线谱目标检测方法[J]. 声学技术, 2021, 40(1): 117–122. doi: [10.16300/j.cnki.1000-3630.2021.01.018](https://doi.org/10.16300/j.cnki.1000-3630.2021.01.018).
WANG Xuecheng, WANG Lujun, and HONG Changwei. A linear spectrum target detection method based on DOA distribution information entropy weighting[J]. *Technical Acoustics*, 2021, 40(1): 117–122. doi: [10.16300/j.cnki.1000-3630.2021.01.018](https://doi.org/10.16300/j.cnki.1000-3630.2021.01.018).
- [4] PARIS S and JAUFFRET C. Frequency line tracking using HMM-based schemes [passive sonar][J]. *IEEE Transactions on Aerospace and Electronic Systems*, 2003, 39(2): 439–449. doi: [10.1109/TAES.2003.1207256](https://doi.org/10.1109/TAES.2003.1207256).
- [5] SONG T L, KIM H W, and MUSICKI D. Iterative joint integrated probabilistic data association for multitarget tracking[J]. *IEEE Transactions on Aerospace and Electronic Systems*, 2015, 51(1): 642–653. doi: [10.1109/TAES.2014.130571](https://doi.org/10.1109/TAES.2014.130571).
- [6] PULFORD G W and LA SCALA B F. Multihypothesis viterbi data association: Algorithm development and assessment[J]. *IEEE Transactions on Aerospace and Electronic Systems*, 2010, 46(2): 583–609. doi: [10.1109/TAES.2010.5461643](https://doi.org/10.1109/TAES.2010.5461643).
- [7] KIM C, LI Fuxin, CIPTADI A, *et al.* Multiple hypothesis tracking revisited[C]. 2015 IEEE International Conference on Computer Vision, Santiago, Chile, 2015: 4696–4704. doi: [10.1109/ICCV.2015.533](https://doi.org/10.1109/ICCV.2015.533).
- [8] STREIT R L and BARRETT R F. Frequency line tracking using hidden Markov models[J]. *IEEE Transactions on Acoustics, Speech, and Signal Processing*, 1990, 38(4): 586–598. doi: [10.1109/29.52700](https://doi.org/10.1109/29.52700).
- [9] BARRETT R F and HOLDSWORTH D A. Frequency tracking using hidden Markov models with amplitude and phase information[J]. *IEEE Transactions on Signal Processing*, 1993, 41(10): 2965–2976. doi: [10.1109/78.277803](https://doi.org/10.1109/78.277803).
- [10] XIE X and EVANS R J. Multiple target tracking and multiple frequency line tracking using hidden Markov

- models[J]. *IEEE Transactions on Signal Processing*, 1991, 39(12): 2659–2676. doi: [10.1109/78.107416](#).
- [11] XIE X and EVANS R J. Multiple frequency line tracking with hidden Markov models - further results[J]. *IEEE Transactions on Signal Processing*, 1993, 41(1): 334. doi: [10.1109/TSP.1993.193150](#).
- [12] XIANYA X and EVANS R J. Multiple frequency line tracking using hidden Markov/A models[C]. The 29th IEEE Conference on Decision and Control, Honolulu, USA, 1990: 847–852. doi: [10.1109/CDC.1990.203708](#).
- [13] XIE Xianya, ZHU Qiang, and LI Huangrun. Some improvements in the HMM based multiple frequency line tracking algorithms[C]. Proceedings of the Third International Conference on Signal Processing, Beijing, China, 1996: 229–232. doi: [10.1109/ICSPGP.1996.567112](#).
- [14] VAN CAPPEL D and ALINAT P. Frequency line extractor using multiple hidden Markov models[C]. IEEE Oceanic Engineering Society. OCEANS'98. Conference Proceedings, Nice, France, 1998: 1481–1485. doi: [10.1109/OCEANS.1998.726317](#).
- [15] PARIS S and JAUFFRET C. A new tracker for multiple frequency line[C]. 2001 IEEE Aerospace Conference Proceedings, Big Sky, USA, 2001: 4/1771–4/1782. doi: [10.1109/AERO.2001.931487](#).
- [16] PULFORD G and TYSON K. A high performance 1-D hidden Markov model tracker for passive sonar systems[C]. Undersea Defence Technology, Rotterdam, Netherlands, 2015.
- [17] LUO Xinwei and SHEN Zihan. A sensing and tracking algorithm for multiple frequency line components in underwater acoustic signals[J]. *Sensors*, 2019, 19(22): 4866. doi: [10.3390/s19224866](#).
- [18] LUO Xinwei and SHEN Zihan. A space-frequency joint detection and tracking method for line-spectrum components of underwater acoustic signals[J]. *Applied Acoustics*, 2021, 172: 107609. doi: [10.1016/j.apacoust.2020.107609](#).
- [19] 吴毅斌, 翟春平, 张宇, 等. 基于隐马尔可夫模型的舰船水下噪声评估方法[J]. 舰船科学技术, 2019, 41(9): 121–124. doi: [10.3404/j.issn.1672-7649.2019.09.023](#).
WU Yibin, ZHAI Chunping, ZHANG Yu, *et al.* Evaluation method of ship's underwater noise based on HMM[J]. *Ship Science and Technology*, 2019, 41(9): 121–124. doi: [10.3404/j.issn.1672-7649.2019.09.023](#).
- [20] ABEL J S, LEE H J, and LOWELL A P. An image processing approach to frequency tracking (application to sonar data)[C]. 1992 IEEE International Conference on Acoustics, Speech, and Signal Processing, San Francisco, USA, 1992: 561–564. doi: [10.1109/ICASSP.1992.225995](#).
- 罗昕炜: 男, 1978年生, 副教授, 博士生导师, 研究方向为统计信号处理、水声信号处理。
- 李 磊: 男, 1998年生, 硕士生, 研究方向为信号与信息处理。
- 沈子涵: 男, 1996年生, 硕士, 研究方向为信号与信息处理。

责任编辑: 马秀强